

# 가설 검정 (Test Hypotheses)

2026-1학기

ICT융합학부 컴퓨터공학트랙

김대환

# 목차

---

1. 가설 검정 (Test Hypotheses)
2. 모델 평가하기 (Assessing a model)
3. 다중 범주 (Multiple Categories)
4. 결정과 불확실성 (Decisions and Uncertainty)
5. 오류 확률 (Error Probabilities)

# 가설 검정

---

# 가설 검정

---

- 가설 검정

- 세상 문제에 대한 Yes-No 질문에 대한 답변 필요
- 예시들
  - 초콜릿은 몸에 좋은가?
  - Broad Street 펌프의 물이 콜레라를 일으켰는가?
  - 지난 10년 동안 캘리포니아의 인구 구성(demographics)은 변했는가?
- 연구(study)와 무작위 실험(randomized experiment)의 데이터를 데이터 과학 방법으로 분석하여 Yes-No 질문들에 답하는 방법
  - 랜덤 표본 (Random samples)
  - 경험적 분포 (Empirical distributions)

# 모델 평가하기

---

# 모델 평가하기 (1)

## ■ 배심원 선정 상황

- 1962년 Alabama의 Talladega County에서 흑인 남성 Robert Swain이 재판을 받음
- 당시 배심원 자격이 있는 남성 중 26%가 흑인이었음
- 하지만 실제 배심원 패널 100명 중 흑인은 8명(8%)뿐이었음
- (Swain 주장) 흑인들이 배심원 선정 과정에서 체계적으로 제외 되었음

➔ 8%라는 결과가 단순 우연으로 가능한가?

## ■ 무작위 선택 모형

- (하나의 가설) 배심원 패널은 26% 흑인인 모집단에서 무작위로 선택 ➔ 흑인이 적은 건 우연 때문
- 모형의 맞는지 확인하기 위해서
  - 컴퓨터 시뮬레이션 수행
  - 26% 흑인 모집단에서 100명을 무작위 추출하는 과정을 수천 번 반복 ➔ 대부분 20~30명 선택

➔ 실제 데이터는 무작위 선택 모형과 잘 맞지 않음

➔ 배심원 선정 과정에서 편향이 있었을 가능성이 매우 큼

# 모델 평가하기 (2)

---

- 통계량 (Statistic)

- 시뮬레이션 할 통계량을 선택해야 함
- 모형과 대안적 관점 사이의 판단을 도와야 함
- 예시
  - (모형) 패널이 무작위 추출
  - (대안적 관점) 패널에 흑인 배심원이 너무 적어서 무작위 추출로 보기 어려움
- 자연스러운 통계량 : 패널 안 흑인 배심원 수 (count) ➔ 작은 값일수록 Swain 주장에 유리

# 모델 평가하기 (3)

- 모형 하에 통계량 시뮬레이션 하기

- 모형이 참 → '통계량은 보통 어느 정도 크기인가?'

→ 무작위 선택 가정 아래 통계량 시뮬레이션 → 결과 분포 (distribution) 확인

- 통계량 하나 시뮬레이션 하기

- sample\_proportions 메소드: 모집단의 비율 분포에서 랜덤 표본을 뽑아 각 범주의 비율을 반환

```
sample_size = 100  
eligible_population = [0.26, 0.74]
```

```
sample_proportions(sample_size, eligible_population).item(0)
```

0.27

```
def one_simulated_count():  
    return sample_size * sample_proportions(sample_size, eligible_population).item(0)
```




# 모델 평가하기 (4)

- 모형 하에 통계량 시뮬레이션 하기 (2)
  - 여러 개의 통계량 값 시뮬레이션 하기

```
counts = make_array()  
repetitions = 10000  
for i in np.arange(repetitions):  
    counts = np.append(counts, one_simulated_count())
```

- 무작위 선택 모형의 예측
  - 시뮬레이션의 결과를 해석하기 위해 히스토그램으로 시각화

```
Table().with_column(  
    'Count in a Random Sample', counts  
) .hist(bins = np.arange(5.5, 46.6, 1))
```




26 근처가 제일 높음 !!

# 모델 평가하기 (5)

## ■ 예측과 실제 데이터 비교

- 실제 재판 패널: 흑인 배심원 8명

```
Table().with_column(  
    'Count in a Random Sample', counts  
) .hist(bins = np.arange(5.5, 46.6, 1))  
plots.ylim(-0.002, 0.09)  
plots.scatter(8, 0, color='red', s=30);
```



선정 과정의 편향 존재 !!

## ■ 데이터 분석의 결론

- 무작위 선택 모형이 실제 데이터와 일치하지 않음
- 우연히 발생했을 가능성은 존재하지만, (시뮬레이션을 통한 결론은) 가능성은 극히 낮음
- 실제 패널은 무작위 선택과 매우 모순!!
- 데이터와 모형이 일치하지 않으면 ➔ 모형은 정당화 되기 어려움  
➔ 이 패널은 무작위 표본 추출이 아니었다 !!

# 모델 평가하기 (6)

- **통계적 편향 (Statistical Bias)**

- (시뮬레이션 분석 결과) Swain 재판의 불공정성에 대한 정량적 증거 제공
- 데이터는 그가 공정한 배심원단을 거부당했음
- 흑인 배심원 배제가 광범위 했음을 보여줌
- 항상 같은 방향으로 오차 발생 → 편향(Bias) 존재 !!

- **인종적 편향 (Racial Bias)**

- 배심원 명단은 도시 명부, 등록 명단, 클럽/교회 명단, 지역 사람들과의 대화, 개인적/사업적 인맥에서 수집 → 흑인에게 불리

# 다중 범주

---

# 다중 범주 (1)

---

- 다중 범주

- 두 범주가 아니라 여러 인종 및 민족 범주(multiple racial and ethnic categories)를 고려
- 기술적으로는 새로운 통계량을 만들어야 함
- 시뮬레이션을 한 후에 관찰되는 차이(discrepancies)의 원인 밝혀야 함

- Alameda County의 배심원 선정 상황

- 2010년 미국 시민자유연맹은 California Alameda County의 배심원 선정에 관한 보고서를 발표
- 특정 인종 및 민족 집단이 배심원 패널에서 과소대표 되었다고 결론
- 배심원 패널 선정 절차에 대한 개혁도 제안
- 민사소송법
  - 배심원 서비스 대상으로 선정되는 모든 사람은 법원이 관할하는 지역 인구를 대표하는 집단에서 무작위로 선택되어야 함

# 다중 범주 (2)

## Alameda County의 배심원 패널 구성


- 연구의 초점: '배심원 패널의 인종 및 민족 구성'
- ACLU 데이터
  - 2009~2010년 Alameda County의 11개 중범죄 재판의 배심원 패널 데이터 수집
  - 배심원 서비스에 출석한 사람 수는 총 1453명
  - 잠재적 배심원의 인구통계 데이터 수집, 이를 배심원 자격 보유자의 분포와 비교
  - (보고서 결과) "other" 범주에는 혼혈(mixed race)이라고 답했지만, 주된 인종 정체성을 밝히지 않은 사람들과 인종/민족 정보를 제공하지 않은 사람들이 포함
  - (첫번째 수치) 적격 배심원(Eligible jurors) 비율, (두번째 수치) 실제 패널 비율

```
jury = Table().with_columns(  
    'Ethnicity', make_array('Asian/PI', 'Black/AA', 'Caucasian', 'Hispanic', 'Other'),  
    'Eligible', make_array(0.15, 0.18, 0.54, 0.12, 0.01),  
    'Panels', make_array(0.26, 0.08, 0.54, 0.08, 0.04)  
)
```

jury

|  | Ethnicity | Eligible | Panels |
|--|-----------|----------|--------|
|  | Asian/PI  | 0.15     | 0.26   |
|  | Black/AA  | 0.18     | 0.08   |
|  | Caucasian | 0.54     | 0.54   |
|  | Hispanic  | 0.12     | 0.08   |
|  | Other     | 0.01     | 0.04   |

```
jury.barh('Ethnicity')
```



# 다중 범주 (3)


## ■ 무작위 선택 패널과의 비교

- 적격 배심원 모집단에서 1453명 랜덤 샘플을 뽑는다면 ➔ 실제 패널 분포와 비슷할까?

```
eligible_population = jury.column('Eligible')  
sample_distribution = sample_proportions(1453, eligible_population)  
panels_and_sample = jury.with_column('Random Sample', sample_distribution)  
panels_and_sample
```

| Ethnicity | Eligible | Panels | Random Sample |
|-----------|----------|--------|---------------|
| Asian/PI  | 0.15     | 0.26   | 0.14384       |
| Black/AA  | 0.18     | 0.08   | 0.163799      |
| Caucasian | 0.54     | 0.54   | 0.538197      |
| Hispanic  | 0.12     | 0.08   | 0.143152      |
| Other     | 0.01     | 0.04   | 0.0110117     |

```
panels_and_sample.barh('Ethnicity')
```



적격 배심원 분포와 비슷,  
하지만 실제 패널 분포는  
그렇지 않음 !!

# 다중 범주 (4)

- 새로운 통계량: 두 분포 사이의 거리
  - 두 분포 사이의 거리를 정량화
  - TVD (Total variation distance)를 계산
    - 각 범주에서 두 비율의 차이를 계산 → 클수록 두 분포는 서로 다름

```
# Augment the table with a column of differences between proportions
jury_with_diffs = jury.with_column(
    'Difference', jury.column('Panels') - jury.column('Eligible')
)
jury_with_diffs
```

```
jury_with_diffs = jury_with_diffs.with_column(
    'Absolute Difference', np.abs(jury_with_diffs.column('Difference'))
)
jury_with_diffs
```

```
jury_with_diffs.column('Absolute Difference').sum() / 2
```

| Ethnicity | Eligible | Panels | Difference |
|-----------|----------|--------|------------|
| Asian/PI  | 0.15     | 0.26   | 0.11       |
| Black/AA  | 0.18     | 0.08   | -0.1       |
| Caucasian | 0.54     | 0.54   | 0          |
| Hispanic  | 0.12     | 0.08   | -0.04      |
| Other     | 0.01     | 0.04   | 0.03       |

| Ethnicity | Eligible | Panels | Difference | Absolute Difference |
|-----------|----------|--------|------------|---------------------|
| Asian/PI  | 0.15     | 0.26   | 0.11       | 0.11                |
| Black/AA  | 0.18     | 0.08   | -0.1       | 0.1                 |
| Caucasian | 0.54     | 0.54   | 0          | 0                   |
| Hispanic  | 0.12     | 0.08   | -0.04      | 0.04                |
| Other     | 0.01     | 0.04   | 0.03       | 0.03                |



# 다중 범주 (5)

- 모형 아래에서 통계량 시뮬레이션 (1)

- 랜덤 샘플에서 TVD가 어떻게 변하는지 보기 위해 → 무작위 선택 모형에서 반복 시뮬레이션 진행

```
def total_variation_distance(distribution_1, distribution_2):  
    return sum(np.abs(distribution_1 - distribution_2)) / 2
```

```
total_variation_distance(jury.column('Panels'), jury.column('Eligible'))
```

0.14

```
sample_distribution = sample_proportions(1453, eligible_population)  
total_variation_distance(sample_distribution, eligible_population)
```

0.018265657260839632

- 통계량 하나 시뮬레이션

```
def one_simulated_tvd():  
    sample_distribution = sample_proportions(1453, eligible_population)  
    return total_variation_distance(sample_distribution, eligible_population)
```

- 여러 개의 통계량 값 시뮬레이션


```
tvds = make_array()  
repetitions = 5000  
for i in np.arange(repetitions):  
    tvds = np.append(tvds, one_simulated_tvd())
```

# 다중 범주 (5)

## ■ 무작위 선택 모형 평가하기

```
Table().with_column('TVD', tvds).hist(bins=np.arange(0, 0.2, 0.005))

# Plotting parameters; you can ignore this code
plots.title('Prediction Assuming Random Selection')
plots.xlim(0, 0.15)
plots.ylim(-5, 50)
plots.scatter(0.14, 0, color='red', s=30);
```



## ■ 편향의 원인

- 배심원 이름은 유권자 등록자와 운전면허/신분증 소지자 목록에서 무작위로 선택
  - ➔ 그 목록에 없는 적격 배심원은 제외되었음
  - ➔ 정부 발급 신분증 보유 여부와 유권자 등록 여부는 소득(income)과 관련된 가능성 높음
  - ➔ 소득은 인종/민족(race/ethnicity)와도 연결 ➔ 흑인/히스패닉은 과소대표
  - ➔ 자원이 부족한 사람들은 고정 주소가 없는 경우가 많음
  - ➔ 연락을 받더라도 실제로 출석 가능해야 함 ➔ 보상도 부족

# 결정과 불확실성

---

# 결정과 불확실성 (1)

---

- 가설 검정 (Hypothesis testing)

- 통계학에서는 데이터를 이용해 어떤 가설이 맞는지 판단
- (예) 멘델의 유전학 실험

- 멘델의 모델

- 멘델은 다음과 같은 모델을 제안
  - 각 완두콩 식물은 75% 확률로 보라색 꽃, 25% 확률로 흰색 꽃
  - 다른 식물과는 독립적
- 실제 929개의 식물을 키웠음 → 그 중 705개가 보라색 꽃이었음

# 결정과 불확실성 (2)

---

- 멘델 모델의 가설 검정 (1)
  - 가설 설정 (Hypotheses)
    - 두 가지 가설 사이에서 선택하는 과정
    - 귀무 가설 (Null Hypothesis)
      - '멘델의 모델이 맞음'
      - 즉 보라색 꽃 확률=75%, 흰색 꽃 확률=25%이고 서로 독립
    - 대립 가설 (Alternative Hypothesis)
      - '멘델의 모델이 맞지 않음'
      - 모델이 맞지 않음만 설명

# 결정과 불확실성 (3)

- 멘델 모델의 가설 검정 (2)

- 검정 통계량 (Test statistic)

- 세운 가설이 맞는지 통계적으로 검증하기 위해, 수집한 표본 데이터에서 계산해 낸 하나의 요약 숫자 값
    - 두 개의 분포를 비교: 멘델 모델의 분포와 무작위 표본에서 얻어진 분포
    - 검정통계량 = **총변동거리 (TVD, total variation distance)**
    - 멘델 모델 분포 = [0.75, 0.25], 표본에서 얻어진 분포 = [0.7, 0.3]

$$\frac{1}{2}(|0.7 - 0.75| + |0.3 - 0.25|) = 0.05 = |0.7 - 0.75|$$

$$|\text{sample percent of purple-flowering plants} - 75|$$

➔ 범주가 2개일 때는 언제나 TVD가 한 범주의 비율 차이와 같다는 사실

- 검정 통계량의 관측값 (Observed value of Test statistic)

- 시뮬레이션된 값이 아니라, 실제 연구 데이터로부터 얻어진 검정통계량의 값

```
observed_statistic = abs ( 100 * (705 / 929) - 75 )
observed_statistic
```

# 결정과 불확실성 (4)

- 멘델 모델의 가설 검정 (3)

- 귀무가설 하에서의 검정 통계량 분포


- 귀무가설이 참이라면 → 검정 통계량이 어떤 값들을 가질 수 있는지를 알아야 함
    - 검정통계량은 귀무가설 모델의 가정들을 바탕으로 시뮬레이션

```
mendel_proportions = make_array(0.75, 0.25)
mendel_proportion_purple = mendel_proportions.item(0)
sample_size = 929
```

```
def one_simulated_distance():
    sample_proportion_purple = sample_proportions(929, mendel_proportions).item(0)
    return 100 * abs(sample_proportion_purple - mendel_proportion_purple)
```

```
repetitions = 10000
distances = make_array()
for i in np.arange(repetitions):
    distances = np.append(distances, one_simulated_distance())
```

```
Table().with_column(
    'Distance between Sample % and 75%', distances
).hist()
plots.title('Prediction Made by the Null Hypothesis');
```



→ 실측을 한 것이 아니라, 멘델의 모델을 사용하여 만들어졌음


# 결정과 불확실성 (5)

## ■ 멘델 모델의 가설 검정 (4)

### ■ 검정의 결론

- 귀무가설과 대립가설 중 무엇을 선택할지는 2단계/3단계에서 계산한 두 가지를 비교하여 결정
  - 검정 통계량의 관측값
  - 귀무가설이 예측한 검정 통계량의 분포
- 둘이 서로 일관되지 않으면, 데이터는 귀무가설을 지지하지 않음. 즉 대립가설을 더 잘 지지
  - ➔ 귀무가설을 기각 (Reject)
- 둘이 일관적이면, 관측된 검정통계량은 귀무가설이 예측한 것과 잘 맞음
  - ➔ 데이터가 귀무가설과 일관적 (Consistent)

```
Table().with_column(  
  'Distance between Sample % and 75%', distances  
)  
.hist()  
plots.ylim(-0.02, 0.5)  
plots.title('Prediction Made by the Null Hypothesis')  
plots.scatter(observed_statistic, 0, color='red', s=40);
```





# 결정과 불확실성 (6)

- 멘델 모델의 가설 검정 (5)

- 일관적(Consistent)이라는 말의 의미

- 때로는 결과가 항상 명확한 것은 아님

- '얼마나 멀어야 먼 것인가?'


- '정확히 어느 정도를 비슷하다고 해야 하나'

→ 보편적인 정답은 없음

- 만약, 다시 실험한 결과가 아래와 같다면?

```
different_observed_statistic = 3.2
Table().with_column(
  'Distance between Sample % and 75%', distances
).hist()
plots.ylim(-0.02, 0.5)
plots.title('Prediction Made by the Null Hypothesis')
plots.scatter(different_observed_statistic, 0, color='red', s=40);
```

→ 어떠한 결론? 일관적인가?



# 결정과 불확실성 (7)

- 멘델 모델의 가설 검정 (6)

- 관례적인 기준(Conventional cut-offs)

- 분포의 꼬리 부분의 면적을 기준으로 함
    - 꼬리 영역의 면적이 작다면, 관측된 통계량은 귀무가설이 가장 흔하게 예측하는 값 들로부터 멀리 떨어져 있다는 뜻

```
np.count_nonzero(distances >= different_observed_statistic) / repetitions
```

0.0243

➔ 상당히 드문 일

- P-value (Probability-value)

- 검정의 관측 유의수준(observed significance level)
    - 귀무가설(차이가 없다)이 맞다는 전제하에, 현재 관측된 데이터(혹은 더 극단적인 결과)가 우연히 나타날 확률
      - $p\text{-value} < 0.05$  ➔ '통계적으로 유의'
      - $p\text{-value} < 0.01$  ➔ '매우 통계적으로 유의'

# 오류 확률

---

# 오류 확률 (1)


## ■ 잘못된 결론

- 귀무가설이 참이 아니라는 대립가설에 대해 귀무가설을 검정

|                     | Test Favors the Null | Test Favors the Alternative |
|---------------------|----------------------|-----------------------------|
| Null is True        | Correct result       | Error                       |
| Alternative is True | Error                | Correct result              |

## ■ 오류의 확률

- (예) 동전이 공정한지 여부를 검정
- 귀무가설(Null): 동전은 공정. 즉, 결과는 앞면과 뒷면에서 복원추출한 무작위 추출과 같음
- 대립가설(Alternative): 동전은 공정하지 않음
- 검정 통계량:  $\text{test statistic} = |\text{number of heads} - 1000|$  → 작으면 귀무가설 지지, 크면 대립가설 지지



```
np.count_nonzero(statistics >= 45) / repetitions
```

0.04654

→ 동전이 실제로 공정하고, 검정이 공정 여부를 판단하기 위해 5% 기준 값을 사용한다면, 검정이 잘못하여 동전이 공정하지 않다고 결론 내릴 확률은 약 5%

# 오류 확률 (2)

- p-value 기준 값은 오류 확률

- p-value에 대해 p% 기준 값을 사용하고, 실제로 귀무가설이 참이라면, 검정이 잘못해서 대립가설이 참이라고 결론 내릴 확률은 약 p%임

|                     | Test Favors the Null | Test Favors the Alternative |
|---------------------|----------------------|-----------------------------|
| Null is True        | Correct result       | Error                       |
| Alternative is True | Error                | Correct result              |

- 오류 통제

- 1% 기준 값은 5% 기준 값보다 더 보수적
- 1% 기준 값을 사용하면, 실제로 귀무가설이 참일 때 잘못해서 "대립가설"이라고 결론 내릴 가능성이 더 작음
- (예) 의학 치료법에 대한 무작위 대조 실험은 보통 1%를 기준 값으로 사용
  - 귀무가설: 치료에는 효과가 없음. 치료군과 대조군 환자들의 결과 차이는 무작위 배정
  - 대립가설: 치료에는 효과가 있음

# 오류 확률 (3)

- 데이터 스누핑과 p-hacking

- (정의) 연구자들이 하나의 데이터로 여러 가설을 반복해서 검정하면, 우연히 유의한 결과 하나가 나올 가능성이 커짐. p-hacking이라고 함
  - p-value 기준을 사용하더라도 우연 때문에 잘못된 "유의한 결과"가 나올 수 있음
  - (예를 들어) 효과가 전혀 없는 치료라도, 많은 연구가 반복되면 일부 연구는 우연히 효과가 있는 것처럼 보일 수 있음
- 연구 결과를 믿기 위해서
  - 몇 개의 가설을 검정했는지 확인해야 하고
  - 같은 실험을 반복해도 같은 결과가 나오는지에 대한 **재현성(replication)**을 검증 필요

# Q & A

---