

가설 검정 (Test Hypotheses) (1)

2026-1학기

ICT융합학부 컴퓨터공학트랙

김대환

목차

1. 가설 검정 (Test Hypotheses)
2. 모델 평가하기 (Assessing a model)
3. 다중 범주 (Multiple Categories)

가설 검정

가설 검정

- 가설 검정

- 세상 문제에 대한 Yes-No 질문에 대한 답변 필요
- 예시들
 - 초콜릿은 몸에 좋은가?
 - Broad Street 펌프의 물이 콜레라를 일으켰는가?
 - 지난 10년 동안 캘리포니아의 인구 구성(demographics)은 변했는가?
- 연구(study)와 무작위 실험(randomized experiment)의 데이터를 데이터 과학 방법으로 분석하여 Yes-No 질문들에 답하는 방법
 - 랜덤 표본 (Random samples)
 - 경험적 분포 (Empirical distributions)

모델 평가하기

모델 평가하기 (1)

■ 배심원 선정 상황

- 1962년 Alabama의 Talladega County에서 흑인 남성 Robert Swain이 재판을 받음
- 당시 배심원 자격이 있는 남성 중 26%가 흑인이었음
- 하지만 실제 배심원 패널 100명 중 흑인은 8명(8%)뿐이었음
- (Swain 주장) 흑인들이 배심원 선정 과정에서 체계적으로 제외 되었음

➔ 8%라는 결과가 단순 우연으로 가능한가?

■ 무작위 선택 모형

- (하나의 가설) 배심원 패널은 26% 흑인인 모집단에서 무작위로 선택 ➔ 흑인이 적은 건 우연 때문
- 모형의 맞는지 확인하기 위해서
 - 컴퓨터 시뮬레이션 수행
 - 26% 흑인 모집단에서 100명을 무작위 추출하는 과정을 수천 번 반복 ➔ 대부분 20~30명 선택

➔ 실제 데이터는 무작위 선택 모형과 잘 맞지 않음

➔ 배심원 선정 과정에서 편향이 있었을 가능성이 매우 큼

모델 평가하기 (2)

- 통계량 (Statistic)

- 시뮬레이션 할 통계량을 선택해야 함
- 모형과 대안적 관점 사이의 판단을 도와야 함
- 예시
 - (모형) 패널이 무작위 추출
 - (대안적 관점) 패널에 흑인 배심원이 너무 적어서 무작위 추출로 보기 어려움
- 자연스러운 통계량 : 패널 안 흑인 배심원 수 (count) ➔ 작은 값일수록 Swain 주장에 유리

모델 평가하기 (3)

- 모형 하에 통계량 시뮬레이션 하기

- 모형이 참 → '통계량은 보통 어느 정도 크기인가?'

→ 무작위 선택 가정 아래 통계량 시뮬레이션 → 결과 분포 (distribution) 확인

- 통계량 하나 시뮬레이션 하기

- sample_proportions 메소드: 모집단의 비율 분포에서 랜덤 표본을 뽑아 각 범주의 비율을 반환

```
sample_size = 100  
eligible_population = [0.26, 0.74]
```

```
sample_proportions(sample_size, eligible_population).item(0)
```

0.27

```
def one_simulated_count():  
    return sample_size * sample_proportions(sample_size, eligible_population).item(0)
```


모델 평가하기 (4)

- 모형 하에 통계량 시뮬레이션 하기 (2)
 - 여러 개의 통계량 값 시뮬레이션 하기

```
counts = make_array()  
repetitions = 10000  
for i in np.arange(repetitions):  
    counts = np.append(counts, one_simulated_count())
```

- 무작위 선택 모형의 예측
 - 시뮬레이션의 결과를 해석하기 위해 히스토그램으로 시각화

```
Table().with_column(  
    'Count in a Random Sample', counts  
) .hist(bins = np.arange(5.5, 46.6, 1))
```




26 근처가 제일 높음 !!

모델 평가하기 (5)

■ 예측과 실제 데이터 비교

- 실제 재판 패널: 흑인 배심원 8명

```
Table().with_column(  
    'Count in a Random Sample', counts  
) .hist(bins = np.arange(5.5, 46.6, 1))  
plots.ylim(-0.002, 0.09)  
plots.scatter(8, 0, color='red', s=30);
```



선정 과정의 편향 존재 !!

■ 데이터 분석의 결론

- 무작위 선택 모형이 실제 데이터와 일치하지 않음
- 우연히 발생했을 가능성은 존재하지만, (시뮬레이션을 통한 결론은) 가능성은 극히 낮음
- 실제 패널은 무작위 선택과 매우 모순!!
- 데이터와 모형이 일치하지 않으면 ➔ 모형은 정당화 되기 어려움
➔ 이 패널은 무작위 표본 추출이 아니었다 !!

모델 평가하기 (6)

- **통계적 편향 (Statistical Bias)**

- (시뮬레이션 분석 결과) Swain 재판의 불공정성에 대한 정량적 증거 제공
- 데이터는 그가 공정한 배심원단을 거부당했음
- 흑인 배심원 배제가 광범위 했음을 보여줌
- 항상 같은 방향으로 오차 발생 → 편향(Bias) 존재 !!

- **인종적 편향 (Racial Bias)**

- 배심원 명단은 도시 명부, 등록 명단, 클럽/교회 명단, 지역 사람들과의 대화, 개인적/사업적 인맥에서 수집 → 흑인에게 불리

다중 범주

다중 범주 (1)

- 다중 범주

- 두 범주가 아니라 여러 인종 및 민족 범주(multiple racial and ethnic categories)를 고려
- 기술적으로는 새로운 통계량을 만들어야 함
- 시뮬레이션을 한 후에 관찰되는 차이(discrepancies)의 원인 밝혀야 함

- Alameda County의 배심원 선정 상황

- 2010년 미국 시민자유연맹은 California Alameda County의 배심원 선정에 관한 보고서를 발표
- 특정 인종 및 민족 집단이 배심원 패널에서 과소대표 되었다고 결론
- 배심원 패널 선정 절차에 대한 개혁도 제안
- 민사소송법
 - 배심원 서비스 대상으로 선정되는 모든 사람은 법원이 관할하는 지역 인구를 대표하는 집단에서 무작위로 선택되어야 함

다중 범주 (2)

Alameda County의 배심원 패널 구성


- 연구의 초점: '배심원 패널의 인종 및 민족 구성'
- ACLU 데이터
 - 2009~2010년 Alameda County의 11개 중범죄 재판의 배심원 패널 데이터 수집
 - 배심원 서비스에 출석한 사람 수는 총 1453명
 - 잠재적 배심원의 인구통계 데이터 수집, 이를 배심원 자격 보유자의 분포와 비교
 - (보고서 결과) "other" 범주에는 혼혈(mixed race)이라고 답했지만, 주된 인종 정체성을 밝히지 않은 사람들과 인종/민족 정보를 제공하지 않은 사람들이 포함
 - (첫번째 수치) 적격 배심원(Eligible jurors) 비율, (두번째 수치) 실제 패널 비율

```
jury = Table().with_columns(  
    'Ethnicity', make_array('Asian/PI', 'Black/AA', 'Caucasian', 'Hispanic', 'Other'),  
    'Eligible', make_array(0.15, 0.18, 0.54, 0.12, 0.01),  
    'Panels', make_array(0.26, 0.08, 0.54, 0.08, 0.04)  
)
```

jury

	Ethnicity	Eligible	Panels
	Asian/PI	0.15	0.26
	Black/AA	0.18	0.08
	Caucasian	0.54	0.54
	Hispanic	0.12	0.08
	Other	0.01	0.04

```
jury.barh('Ethnicity')
```



다중 범주 (3)


■ 무작위 선택 패널과의 비교

- 적격 배심원 모집단에서 1453명 랜덤 샘플을 뽑는다면 ➔ 실제 패널 분포와 비슷할까?

```
eligible_population = jury.column('Eligible')
sample_distribution = sample_proportions(1453, eligible_population)
panels_and_sample = jury.with_column('Random Sample', sample_distribution)
panels_and_sample
```

Ethnicity	Eligible	Panels	Random Sample
Asian/PI	0.15	0.26	0.14384
Black/AA	0.18	0.08	0.163799
Caucasian	0.54	0.54	0.538197
Hispanic	0.12	0.08	0.143152
Other	0.01	0.04	0.0110117

```
panels_and_sample.barh('Ethnicity')
```



적격 배심원 분포와 비슷,
하지만 실제 패널 분포는
그렇지 않음 !!

다중 범주 (4)

- 새로운 통계량: 두 분포 사이의 거리
 - 두 분포 사이의 거리를 정량화
 - TVD (Total variation distance)를 계산
 - 각 범주에서 두 비율의 차이를 계산 → 클수록 두 분포는 서로 다름

```
# Augment the table with a column of differences between proportions
jury_with_diffs = jury.with_column(
    'Difference', jury.column('Panels') - jury.column('Eligible')
)
jury_with_diffs
```

```
jury_with_diffs = jury_with_diffs.with_column(
    'Absolute Difference', np.abs(jury_with_diffs.column('Difference'))
)
jury_with_diffs
```

```
jury_with_diffs.column('Absolute Difference').sum() / 2
```

Ethnicity	Eligible	Panels	Difference
Asian/PI	0.15	0.26	0.11
Black/AA	0.18	0.08	-0.1
Caucasian	0.54	0.54	0
Hispanic	0.12	0.08	-0.04
Other	0.01	0.04	0.03

Ethnicity	Eligible	Panels	Difference	Absolute Difference
Asian/PI	0.15	0.26	0.11	0.11
Black/AA	0.18	0.08	-0.1	0.1
Caucasian	0.54	0.54	0	0
Hispanic	0.12	0.08	-0.04	0.04
Other	0.01	0.04	0.03	0.03

다중 범주 (5)

- 모형 아래에서 통계량 시뮬레이션 (1)

- 랜덤 샘플에서 TVD가 어떻게 변하는지 보기 위해 → 무작위 선택 모형에서 반복 시뮬레이션 진행

```
def total_variation_distance(distribution_1, distribution_2):  
    return sum(np.abs(distribution_1 - distribution_2)) / 2
```

```
total_variation_distance(jury.column('Panels'), jury.column('Eligible'))
```

0.14

```
sample_distribution = sample_proportions(1453, eligible_population)  
total_variation_distance(sample_distribution, eligible_population)
```

0.018265657260839632

- 통계량 하나 시뮬레이션

```
def one_simulated_tvd():  
    sample_distribution = sample_proportions(1453, eligible_population)  
    return total_variation_distance(sample_distribution, eligible_population)
```

- 여러 개의 통계량 값 시뮬레이션


```
tvds = make_array()  
repetitions = 5000  
for i in np.arange(repetitions):  
    tvds = np.append(tvds, one_simulated_tvd())
```

다중 범주 (5)

■ 무작위 선택 모형 평가하기

```
Table().with_column('TVD', tvds).hist(bins=np.arange(0, 0.2, 0.005))

# Plotting parameters; you can ignore this code
plots.title('Prediction Assuming Random Selection')
plots.xlim(0, 0.15)
plots.ylim(-5, 50)
plots.scatter(0.14, 0, color='red', s=30);
```



■ 편향의 원인

- 배심원 이름은 유권자 등록자와 운전면허/신분증 소지자 목록에서 무작위로 선택
 - ➔ 그 목록에 없는 적격 배심원은 제외되었음
 - ➔ 정부 발급 신분증 보유 여부와 유권자 등록 여부는 소득(income)과 관련된 가능성 높음
 - ➔ 소득은 인종/민족(race/ethnicity)와도 연결 ➔ 흑인/히스패닉은 과소대표
 - ➔ 자원이 부족한 사람들은 고정 주소가 없는 경우가 많음
 - ➔ 연락을 받더라도 실제로 출석 가능해야 함 ➔ 보상도 부족

Q & A
