

예측

2026-1학기

ICT융합학부 컴퓨터공학트랙

김대환

목차

1. 개요
2. 상관 (Correlation)
3. 회귀 직선 (Regression Line)
4. 최소제곱법 (Method of Least Squares)
5. 최소 제곱 회귀 (Least Squares Regression)
6. 시각적 진단 (Visual Diagnostics)
7. 수치적 진단 (Numerical Diagnostics)

개요

예측 (1)

- 데이터로 미래 예측

- 한 변수의 값으로 다른 변수의 값을 예측하는 가장 일반적인 방법을 배움

- 예제: 부모 키로 자녀키 예측 (934명)


- https://github.com/mdogy/dataForEng1999/blob/master/family_heights.csv

```
# Data on heights of parents and their adult children
original = Table.read_table(path_data + 'family_heights.csv')
heights = Table().with_columns(
    'MidParent', original.column('midparentHeight'),
    'Child', original.column('childHeight')
)
```

heights

MidParent	Child
75.43	73.2
75.43	69.2
75.43	69
75.43	69

```
heights.scatter('MidParent')
```




예측 (2)

- 예제: 부모 키로 자녀 키 예측 (934명) (2)
 - 중간 부모 키가 $\text{MidParent} \pm 0.5$ 인치인 자녀들의 평균 키를 반환

```
def predict_child(mpht):  
    """Return a prediction of the height of a child  
    whose parents have a midparent height of mpht.  
  
    The prediction is the average height of the children  
    whose midparent height is in the range mpht plus or minus 0.5 inches.  
    """  
  
    close_points = heights.where('MidParent', are.between(mpht-0.5, mpht + 0.5))  
    return close_points.column('Child').mean()
```

```
# Apply predict_child to all the midparent heights  
  
heights_with_predictions = heights.with_column(  
    'Prediction', heights.apply(predict_child, 'MidParent')  
)
```

```
# Draw the original scatter plot along with the predicted values  
  
heights_with_predictions.scatter('MidParent')
```



➔ 수직 띠의 중심을 잇는 예측 방법을
회귀(Regression)이라고 함

상관 (Correlation)

상관 (1)

■ 선형 연관성 (Linear association)

- 산점도가 직선 주위에 얼마나 조밀하게 모여 있는지 측정

■ 예제: 하이브리드 차량 데이터 (1997~2013)

- <https://github.com/data-8/materials-fa17/blob/master/lec/hybrid.csv>

```
hybrid = Table.read_table(path_data + 'hybrid.csv')
```

vehicle	year	msrp	acceleration	mpg	class
Prius (1st Gen)	1997	24509.7	7.46	41.26	Compact
Tino	2000	35355	8.2	54.1	Compact
Prius (2nd Gen)	2000	26832.2	7.97	45.23	Compact
Insight	2000	18936.4	9.52	53	Two Seater
Civic (1st Gen)	2001	25833.4	7.04	47.04	Compact
Insight	2001	19036.7	9.52	53	Two Seater
Insight	2002	19137	9.71	53	Two Seater
Alphard	2003	38084.8	8.33	40.46	Minivan
Insight	2003	19137	9.52	53	Two Seater
Civic	2003	14071.9	8.62	41	Compact


(143 rows omitted)

- **vehicle**: model of the car
- **year**: year of manufacture
- **msrp**: manufacturer's suggested retail price in 2013 dollars
- **acceleration**: acceleration rate in km per hour per second
- **mpg**: fuel economy in miles per gallon
- **class**: the model's class.

상관 (2)


예제: 하이브리드 차량 데이터 (1997~2013) (2)

```
hybrid.scatter('acceleration', 'msrp')
```




양 (positive)의 연관 (우상향)

```
hybrid.scatter('mpg', 'msrp')
```



음 (negative)의 연관 + 비선형(곡선)

```
suv = hybrid.where('class', 'SUV')  
suv.scatter('mpg', 'msrp')
```



suv로 한정, 음의 연관


➔ 산점도의 방향/모양만으로도 연관성을 이해할 수 있음

상관 (3)

■ 예제: 하이브리드 차량 데이터 (1997~2013) (3)


- 표준 단위로 변환
 - 측정 단위에 신경 쓰지 않아도 됨
 - 동일한 축 척도에서 비교 가능

```
Table().with_columns(  
    'mpg (standard units)', standard_units(suv.column('mpg')),  
    'msrp (standard units)', standard_units(suv.column('msrp'))  
)  
.scatter(0, 1)  
plots.xlim(-3, 3)  
plots.ylim(-3, 3);
```



```
def standard_units(any_numbers):  
    "Convert any array of numbers to standard units."  
    return (any_numbers - np.mean(any_numbers))/np.std(any_numbers)
```

```
Table().with_columns(  
    'acceleration (standard units)', standard_units(suv.column('acceleration')),  
    'msrp (standard units)', standard_units(suv.column('msrp'))  
)  
.scatter(0, 1)  
plots.xlim(-3, 3)  
plots.ylim(-3, 3);
```



상관 (4)


■ 상관 계수 (Correlation coefficient)

- 두 변수 사이의 선형 관계의 강도를 측정
- 산점도가 직선 주위에 얼마나 모여 있는지를 나타냄
- 기호 r 로 표기


■ 수학적 성질

- The correlation coefficient r is a number between -1 and 1.
- r measures the extent to which the scatter plot clusters around a straight line.
- $r = 1$ if the scatter diagram is a perfect straight line sloping upwards, and $r = -1$ if the scatter diagram is a perfect straight line sloping downwards.


`r_scatter(0.9)`




`r_scatter(0.25)`



`r_scatter(0)`



`r_scatter(-0.55)`



상관 (5)

■ 상관 계수 계산하기

- 상관 계수 r 의 정의: 두 변수를 모두 표준단위로 측정했을 때, 두 변수 곱의 평균

```
x = np.arange(1, 7, 1)
y = make_array(2, 3, 1, 5, 2, 7)
t = Table().with_columns(
    'x', x,
    'y', y
)
```

① 각 변수를 표준 단위로 변환

```
t_su = t.with_columns(
    'x (standard units)', standard_units(x),
    'y (standard units)', standard_units(y)
)
t_su
```

x	y	x (standard units)	y (standard units)
1	2	-1.46385	-0.648886
2	3	-0.87831	-0.162221
3	1	-0.29277	-1.13555
4	5	0.29277	0.811107
5	2	0.87831	-0.648886
6	7	1.46385	1.78444

② 표준 단위 쌍을 서로 곱함


```
t_product = t_su.with_column('product of standard units', t_su.column(2) * t_su.column(3))
t_product
```

x	y	x (standard units)	y (standard units)	product of standard units
1	2	-1.46385	-0.648886	0.949871
2	3	-0.87831	-0.162221	0.142481
3	1	-0.29277	-1.13555	0.332455
4	5	0.29277	0.811107	0.237468
5	2	0.87831	-0.648886	-0.569923
6	7	1.46385	1.78444	2.61215

③ 2단계에서 구한 곱들의 평균

```
# r is the average of the products of standard units
r = np.mean(t_product.column(4))
r
```

0.6174163971897709




상관 (6)

■ 상관 계수의 성질

- r 의 단위가 없는 순수한 수 (표준 단위 기반)
- 어느 축의 단위를 바꿔도 r 은 영향받지 않음 (표준 단위 기반)
- 두 축을 서로 바꿔도 r 은 변하지 않음
 - 표준단위의 곱은 어느 변수를 x 라 하고 y 라 하든 동일하기 때문
 - 기하학적으로 축 교환은 산점도를 직선 $y = x$ 에 대해 반사시킬 뿐, 모여 있는 정도나 연관성의 부호는 바꾸지 않음

```
t.scatter('y', 'x', s=30, color='red')
```



상관 (7)

▪ 'correlation' 함수

- 상관계수 값을 구하는 함수
- 표와 두 열 이름을 받아 표준단위 곱의 평균(r)을 반환

```
def correlation(t, x, y):  
    return np.mean(standard_units(t.column(x))*standard_units(t.column(y)))
```

```
correlation(t, 'x', 'y')
```

0.6174163971897709

```
correlation(t, 'y', 'x')
```

0.6174163971897709

```
correlation(suv, 'mpg', 'msrp')
```

-0.6667143635709919

```
correlation(suv, 'acceleration', 'msrp')
```

0.48699799279959155

➔ 가격-연비는 음의 연관, 가격-가속은 양의 연관

➔ 가격-가속의 선형 관계(상관 약 0.5)가 가격-연비(상관 약 -0.67)보다 조금 더 약함


▪ 연관은 인과가 아님

- 상관은 오직 **연관**만을 측정하며, **인과관계를 의미하지 않음**
- (예) 어느 학군 아이들의 체중과 수학 실력 사이에 양의 상관 ➔ 수학을 한다고 살이 찌거나 살이 찌다고 수학을 잘하게 되는 것은 아님 ➔ 나이가 교란 변수임 (나이가 많으면 평균적으로 무겁고 수학도 더 잘함)

상관 (8)

- 상관은 선형 연관만 측정
 - 상관은 오직 한 종류의 연관, 즉 **선형** 연관만 측정
 - 강한 비선형 관계를 가진 변수들도 상관은 매우 낮을 수 있음

```
new_x = np.arange(-4, 4.1, 0.5)
nonlinear = Table().with_columns(
    'x', new_x,
    'y', new_x**2
)
nonlinear.scatter('x', 'y', s=30, color='r')
```



```
correlation(nonlinear, 'x', 'y')
```


0.0

➔ 완벽한 $y=x^2$ 이차 관계이지만, 상관이 0임

상관 (9)

- 상관은 이상치 (Outlier)에 영향 받음
 - 이상치 하나가 상관에 큰 영향을 줄 수 있음
 - (예) $r = 1$ 이던 산점도에 단 하나의 이상점을 추가하자 $r = 0$ 이 됨


```
line = Table().with_columns(  
    'x', make_array(1, 2, 3, 4),  
    'y', make_array(1, 2, 3, 4)  
)  
line.scatter('x', 'y', s=30, color='r')
```



```
correlation(line, 'x', 'y')
```

1.0

```
outlier = Table().with_columns(  
    'x', make_array(1, 2, 3, 4, 5),  
    'y', make_array(1, 2, 3, 4, 0)  
)  
outlier.scatter('x', 'y', s=30, color='r')
```



```
correlation(outlier, 'x', 'y')
```

0.0

상관 (10)

- 생태학적 상관은 신중히 해석

- 집계(aggregate)된 데이터에 기반한 상관은 오해 가능
- (예) $r = 1$ 이던 산점도에 단 하나의 이상점을 추가하자 $r = 0$ 이 됨

- 예제: 2014년 SAT의 비판적 읽기와 수학 점수 데이터


- <https://github.com/data-8/materials-sp18/blob/master/lec/sat2014.csv>

```
sat2014 = Table.read_table(path_data + 'sat2014.csv').sort('State')
sat2014
```

State	Participation Rate	Critical Reading	Math	Writing	Combined
Alabama	6.7	547	538	532	1617
Alaska	54.2	507	503	475	1485
Arizona	36.4	522	525	500	1547
Arkansas	4.2	573	571	554	1698
California	60.3	498	510	496	1504
Colorado	14.3	582	586	567	1735
Connecticut	88.4	507	510	508	1525
Delaware	100	456	459	444	1359
District of Columbia	100	440	438	431	1309
Florida	72.2	491	485	472	1448

... (41 rows omitted)

```
sat2014.scatter('Critical Reading', 'Math')
```




```
correlation(sat2014, 'Critical Reading', 'Math')
```

0.9847558411067434

➔ 주별 학생 평균 데이터이기에,
실제 학생들의 데이터를 보면 상
관도가 낮아짐

상관 (11)

진지한 연구? 농담?



국가별 초콜릿 소비량과 노벨상 수상 사이의 관계

Q & A
