

회귀를 위한 추론

2026-1학기

ICT융합학부 컴퓨터공학트랙

김대환

목차

1. 개요
2. 회귀 모형 (Regression Model)
3. 참 기울기를 위한 추론 (Inference for the True Slope)
4. 예측 구간 (Prediction Intervals)

개요

회귀를 위한 추론

■ 회귀 모델(Regression Model)이란?

- 추론적 사고는 항상 데이터에 대한 가정(모델)을 먼저 검토하는 것에서 시작
- 선형적으로 보이는 산점도의 무작위성에 대한 가정들의 집합 = 회귀 모델
 - 진짜 선(True Line): 실제로는 볼 수 없는 모집단의 숨겨진 선형 관계
 - 오차(Error): 평균 0, 정규분포를 따르는 무작위 노이즈 → 점들이 선에서 위아래로 흩어짐

■ 회귀선은 진짜 선의 추정값

- 우리가 실제로 보는 것은 표본 데이터뿐 → 회귀선으로 진짜 선을 추정
- 표본 크기가 클수록 회귀선이 진짜 선에 더 가까워짐 (시뮬레이션으로 확인 가능)

■ 진짜 기울기 추정: 부트스트랩(Bootstrap)

- 원래 표본에서 복원 추출을 반복 → 각 부트스트랩 표본마다 회귀선 기울기 계산
- 기울기들의 분포를 구하면 95% 신뢰구간 계산 가능 → 진짜 기울기가 0인지(관계 없음) 검정 가능

회귀 모형

회귀 모형 (1)

- 회귀 모형의 핵심 아이디어

- 두 변수 사이의 진짜 관계는 **완벽한 직선(신호, Signal)** → 우리 눈에는 보이지 않음
- 직선 주변에 흩어진 점들 → 각 점에서 결과 + **무작위 노이즈(Noise)에 의해 오염**
- (추론 목표) 노이즈 속에서 신호(진짜 선)를 분리해 내는 것

- 산점도 데이터 무작위 생성 과정 (모델 가정)

- ① 각 x 에 대해 참 직선 위치 대응하는 점을 찾음 → 잡음. 즉 오차 생성
- ② 오차(Error)를 추가 → 평균 0인 정규분포에서 무작위로 추출
- ③ 실제 데이터 포인트 = (x , 진짜 선의 y 값 + 오차) → 선의 위아래로 흩어짐
- ④ 진짜 선은 지운다 → 우리가 실제로 관측하는 것은 점들만!

회귀 모형 (2)

■ 회귀선 vs 진짜 선

- 진짜 선(True Line): 볼 수 없는 숨겨진 모집단의 선형 관계
- 회귀선(Regression Line): 표본 데이터로 구한 최적합 직선 (진짜 선의 추정값)
- 표본이 충분히 클수록 회귀선 $\approx$ 진짜 선에 더 가까워짐

■ 시뮬레이션: draw_and_compare (기울기, 절편, 표본 크기)





- 1단계: 진짜 선 + 생성된 점
- 2단계: 우리에게 보이는 산점도 (진짜 선 없음)
- 3단계: 회귀선 (추정값)
- 4단계: 회귀선 + 진짜 선 비교

```
# The true line,  
# the points created,  
# and our estimate of the true line.  
# Arguments: true slope, true intercept, number of points
```

```
draw_and_compare(4, -5, 10)
```

■ 핵심 결론

- 회귀 모델 타당 + **충분히 큰 표본** $\rightarrow$ 회귀선은 진짜 선의 훌륭한 근사값
- 현실에서는 진짜 선을 볼 수 없음 $\rightarrow$ 항상 데이터로부터 추정할 뿐!



참 기울기를 위한 추론

참 기울기를 위한 추론 (1)


- 진짜 기울기(True Slope) 추정

- 회귀 모델 성립/표본이 크면 → 회귀선 $\approx$ 진짜 선 (True line) → 진짜 기울기 추정 가능

- (예제) 산모와 신생아 표본

- 출생체중 vs 임신기간(Gestational Days) 관계 설명 회귀 모델
- 산점도: 직선 주변에 점들이 비교적 고르게 분포 → 회귀 모델 타당

```
scatter_fit(baby, 'Gestational Days', 'Birth Weight')
```



```
correlation(baby, 'Gestational Days', 'Birth Weight')
```

0.40754279338885108

→ 상관계수(r) = 0.408 양의 기울기

```
slope(baby, 'Gestational Days', 'Birth Weight')
```

0.46655687694921522

→ 회귀선 기울기 = 0.467 온스/일

- 핵심 질문

- 표본이 달라지면 회귀선도 달라짐 → 기울기가 얼마나 달라질 수 있을까?
- (해결책) 새 표본을 구하기 어려울 때 → **원래 표본에서 부트스트랩!**


참 기울기를 위한 추론 (2)

■ 산점도 부트스트랩 (Bootstrapping the Scatter Plot)

- 원래 표본에서 **복원 추출(with replacement)**로 같은 크기의 새 표본 생성
- 새 표본으로 만든 산점도 = **산점도 부트스트랩**
- (특징) 일부 원래 점이 선택되지 않아 원본보다 약간 희소(sparse)하게 보임

■ 왜 부트스트랩인가?

- 현실에서는 추가 표본을 구하기 어려움 → 원래 표본 하나만 존재
- 부트스트랩으로 표본의 변동성을 시뮬레이션 → 기울기의 불확실성 추정 가능



→ 각 부트스트랩 산점도마다 다른 회귀선(기울기)이 생성됨

참 기울기를 위한 추론 (3)

진짜 기울기 추정 방법


- ① 원래 표본을 N번 부트스트랩
- ② 각 부트스트랩 산점도마다 회귀선 기울기 계산 → 기울기 수집
- ③ 기울기들의 히스토그램을 그려 분포 확인

```
slopes = make_array()
for i in np.arange(5000):
    bootstrap_sample = baby.sample()
    bootstrap_slope = slope(bootstrap_sample, 'Gestational Days', 'Birth Weight')
    slopes = np.append(slopes, bootstrap_slope)
Table().with_column('Bootstrap Slopes', slopes).hist(bins=20)
```

```
left = percentile(2.5, slopes)
right = percentile(97.5, slopes)
left, right
```

(0.38169251837495338, 0.55839374914417184)

- 95% 신뢰구간 (백분위수 방법)
- 2.5번째 ~ 97.5번째 백분위수 구간



출생체중 vs 임신기간

- 관측된 기울기: **0.467 온스/일**
- 진짜 기울기의 근사 95% 신뢰구간: **약 0.38 ~ 0.56 온스/일**
- 해석: 임신기간이 하루 늘어날 때 출생체중이 약 0.38~0.56 온스 증가한다고 추정

참 기울기를 위한 추론 (4)

▪ bootstrap_slope 함수 (자동화)


▪ bootstrap_slope(table, x, y, repetitions)

▪ ① 부트스트랩 기울기 히스토그램 ② 95% 신뢰구간 노란 막대 ③ 수치 출력


```
def bootstrap_slope(table, x, y, repetitions):  
    # For each repetition:  
    # Bootstrap the scatter, get the slope of the regression line,  
    # augment the list of generated slopes  
    slopes = make_array()  
    for i in np.arange(repetitions):  
        bootstrap_sample = table.sample()  
        bootstrap_slope = slope(bootstrap_sample, x, y)  
        slopes = np.append(slopes, bootstrap_slope)  
  
    # Find the endpoints of the 95% confidence interval for the true slope  
    left = percentile(2.5, slopes)  
    right = percentile(97.5, slopes)  
  
    # Slope of the regression line from the original sample  
    observed_slope = slope(table, x, y)  
  
    # Display results  
    Table().with_column('Bootstrap Slopes', slopes).hist(bins=20)  
    plots.plot(make_array(left, right), make_array(0, 0), color='yellow', lw=8);  
    print('Slope of regression line:', observed_slope)  
    print('Approximate 95%-confidence interval for the true slope:')  
    print(left, right)
```

```
bootstrap_slope(baby, 'Gestational Days', 'Birth Weight', 5000)
```

Slope of regression line: 0.466556876949
Approximate 95%-confidence interval for the true slope:
0.380373502308 0.558711930778



```
scatter_fit(baby, 'Maternal Height', 'Birth Weight')
```



```
correlation(baby, 'Maternal Height', 'Birth Weight')
```

0.20370417718968034


```
bootstrap_slope(baby, 'Maternal Height', 'Birth Weight', 5000)
```

➔ 상관계수: $r \approx 0.20$ (임신기간보다 낮지만 회귀 모델 적합)

➔ 관측 기울기: 1.478 온스/인치

➔ 95% 신뢰구간: 약 1.07 ~ 1.91 온스/인치


Slope of regression line: 1.47801935193
Approximate 95%-confidence interval for the true slope:
1.06617289982 1.91237018475



참 기울기를 위한 추론 (5)

- 진짜 기울기가 0일 수 있는가? (가설 검정)
 - 회귀선이 완전히 평평하지 않더라도, 그것이 우연일 수 있음(기울기=0인 진짜 선에서 랜덤하게)
 - (시뮬레이션) 진짜 기울기=0으로 설정 → 회귀선의 기울기는 거의 항상 0이 아님

```
draw_and_compare(0, 10, 25)
```



- 가설 검정 방법
 - 귀무가설(H_0):** 진짜 선의 기울기는 0이다 (선형 관계 없음)
 - 대립가설(H_1):** 진짜 선의 기울기는 0이 아니다 (선형 관계 있음)
 - (판단 기준) **95% 신뢰구간에 0이 포함되지** 확인


참 기울기를 위한 추론 (6)

■ 가설 검정 방법 (2)

```
slope(baby, 'Maternal Age', 'Birth Weight')
```


0.085007669415825132

```
scatter_fit(baby, 'Maternal Age', 'Birth Weight')
```



```
bootstrap_slope(baby, 'Maternal Age', 'Birth Weight', 5000)
```

Slope of regression line: 0.0850076694158
Approximate 95%-confidence interval for the true slope:
-0.104436940365 0.276512953946



■ 적용 예: 출생체중 vs 산모 나이

- 관측 기울기: 0.085 온스/년 (매우 작고 거의 평평)
- 95% 신뢰구간: **약 -0.10 ~ +0.28 온스/년** → **0 포함!**
- 결론: 귀무가설 기각 불가 → 산모 나이로 출생체중을 예측하는 것은 **부적절**

예측 구간

예측 구간 (1)

■ 예측 구간이란?

- (회귀의 목적) 원래 표본에 없던 **새 개체의 y 값**을 예측
- 이상적으로는 진짜 선의 높이를 알고 싶지만 → 대신 회귀선(표본)을 사용
- 예측에는 불확실성이 있다 → 단일 값 대신 **구간(Interval)**으로 표현


■ 적합값(Fitted Value)

- 주어진 x에서 회귀선의 높이 = **적합값** → y의 회귀 추정값
- **fitted_value(table, x, y, given_x)**: 기울기 × given_x + 절편

```
def fitted_value(table, x, y, given_x):  
    a = slope(table, x, y)  
    b = intercept(table, x, y)  
    return a * given_x + b
```

```
fit_300 = fitted_value(baby, 'Gestational Days', 'Birth Weight', 300)  
fit_300
```

129.2129241703143




➔ 약 129.2 온스 ≈ 임신기간 300일인
아기의 예측 출생체중

예측 구간 (2)

■ 예측의 변동성(Variability)

- 표본이 달라지면 → 회귀선도 달라지고 → **예측값도 달라짐**
- 예측이 얼마나 달라질 수 있는지 파악해야 예측의 신뢰도를 알 수 있음
- 부트스트랩으로 새 표본 생성하여 변동성 확보
 - ① 부트스트랩으로 산점도를 반복 재표본
 - ② 각 부트스트랩 산점도마다 회귀선을 그리고 $x=300$ 에서 예측값 계산
 - ③ 10개의 부트스트랩 회귀선 → 예측값마다 차이가 존재함을 시각적으로 확인



lines		
slope	intercept	prediction at x=300
0.431704	-1.10973	128.402
0.512942	-23.6503	130.232
0.450939	-6.73161	128.55
0.447632	-5.68583	128.604
0.353555	20.1531	126.22
0.469301	-11.6276	129.163
0.445023	-5.01298	128.494
0.540571	-31.3711	130.8
0.487377	-16.8051	129.408
0.451658	-5.45954	130.038

→ 10개의 선마다 기울기와 절편이 다름
→ $x=300$ 에서의 예측 값도 각각 다름

예측 구간 (3)

■ 부트스트랩 예측 구간

- 매 반복마다 부트스트랩 표본 → 적합값 계산 → 모든 예측값 수집
- 예측값 히스토그램 + 95% 예측 구간(노란 막대) + 수치 출력

```
# Bootstrap prediction of variable y at new_x
# Data contained in table; prediction by regression of y based on x
# repetitions = number of bootstrap replications of the original scatter plot

def bootstrap_prediction(table, x, y, new_x, repetitions):

    # For each repetition:
    # Bootstrap the scatter;
    # get the regression prediction at new_x;
    # augment the predictions list
    predictions = make_array()
    for i in np.arange(repetitions):
        bootstrap_sample = table.sample()
        bootstrap_prediction = fitted_value(bootstrap_sample, x, y, new_x)
        predictions = np.append(predictions, bootstrap_prediction)

    # Find the ends of the approximate 95% prediction interval
    left = percentile(2.5, predictions)
    right = percentile(97.5, predictions)

    # Prediction based on original sample
    original = fitted_value(table, x, y, new_x)


    # Display results
    Table().with_column('Prediction', predictions).hist(bins=20)
    plots.xlabel('predictions at x='+str(new_x))
    plots.plot(make_array(left, right), make_array(0, 0), color='yellow', lw=8);
    print('Height of regression line at x='+str(new_x)+':', original)
    print('Approximate 95%-confidence interval:')
    print(left, right)
```

```
bootstrap_prediction(baby, 'Gestational Days', 'Birth Weight', 300, 5000)
```

Height of regression line at x=300: 129.2129241703143

Approximate 95%-confidence interval:

127.30986480617071 131.3039886526053



- ➔ 5,000번 반복 → 예측값 분포가 정규분포에 가까움
- ➔ 회귀선의 예측값: 129.2 온스 (구간의 중앙 근처)
- ➔ 근사 95% 예측 구간: 약 127 ~ 131 온스

예측 구간 (4)

■ 예측변수 값의 변경에 따른 효과

■ x 값의 위치에 따른 구간 폭 변화



- x = 285일 (평균에 가까움): 예측값 ≈ 122.2 온스, 구간 **약 121 ~ 123 온스**
- x = 300일 (평균보다 멀리): 예측값 ≈ 129.2 온스, 구간 **약 127 ~ 131 온스 (더 넓음)**

```
bootstrap_prediction(baby, 'Gestational Days', 'Birth Weight', 285, 5000)
```

Height of regression line at x=285: 122.21457101607608
Approximate 95%-confidence interval:
121.15559627774567 123.29019769886106

```
np.mean(baby.column('Gestational Days'))
```

279.1013628620102



- ➔ 회귀선들은 분포 중심(평균)에서 교차하는 경향 → 끝쪽으로 갈수록 더 많이 벌어짐
- ➔ 따라서 데이터 범위 밖에서는 예측 불확실성이 급격히 증가

■ 왜 평균 근처에서 구간이 더 좁은가?

- 임신기간 평균: **약 279일** → 285는 평균 가까이, 300은 평균에서 멀
- 부트스트랩 회귀선들은 **분포의 중심 근처에서는 서로 가깝게** 모임
 - ➔ 중심 가까운 x: 예측값 변동 작음 = **좁은 구간**
 - ➔ 중심 멀리 있는 x: 예측값 변동 큼 = **넓은 구간**

Q & A
